

Machine Learning Project

To bee or not to bee

MAMA Abbas

MARDAY Naomie

TIR Omar

Juin 2026

1. Introduction

Ce rapport présente le travail réalisé dans le cadre du projet de Machine Learning. L'objectif est de classifier des insectes pollinisateurs en se basant sur des features extraites d'images haute résolution et de leurs masques de segmentation.

Le dataset contient 347 images. Les 250 premières servent à l'entraînement et sont accompagnées de labels (fichier classif.xlsx avec deux colonnes : « bug type » et « species »). Les images 251 à 347 constituent le test set, fourni sans labels, sur lequel on applique le modèle final pour produire le CSV de soumission.

Après nettoyage du dataset, on retient 248 images réparties en 5 classes : Bee (115), Bumblebee (100), Butterfly (15), Hover fly (9) et Wasp (9). La classe Dragonfly (1 échantillon) a été exclue car un seul exemple ne permet ni l'entraînement ni la cross-validation stratifiée. La classe « Bee & Bumblebee » (1 échantillon) a été fusionnée dans Bee.

2. Feature Extraction

L'extraction de features transforme chaque image en un vecteur numérique exploitable par les algorithmes. On utilise le masque de segmentation pour isoler les pixels appartenant à l'insecte. Au total, environ 40 features sont extraites par image.

2.1 Features obligatoires

Les features demandées dans le cahier des charges sont les suivantes :

Feature	Description	Nb
Symétrie de forme	Recouvrement entre le masque et son flip horizontal, sur la bounding box	1
Symétrie de couleur	Différence absolue moyenne RGB entre moitié gauche et droite, normalisée [0,1]	1
Ratio de pixels	Pixels insecte / pixels totaux de l'image	1
RGB min, max, mean	Min, max et moyenne pour R, G, B dans le masque	9
RGB median, std	Médiane et écart-type pour R, G, B dans le masque	6

Total features obligatoires : 18

2.2 Features supplémentaires choisies

En plus des features obligatoires, on a ajouté des descripteurs qui améliorent la séparation des classes. Le passage de 18 features à ~40 a permis de gagner +16 points de F1 macro (de 0.60 à 0.76).

Catégorie	Features	Justification
Forme (regionprops)	aspect_ratio, circularity, solidity, eccentricity, extent, axes, diameter	Abeilles et bourdons diffèrent en compacité et élongation
Moments de Hu	7 moments invariants (hu_1 à hu_7)	Invariants rotation/échelle, capturent la géométrie globale
HSV	h_mean, h_std, s_mean, s_std, v_mean, v_std	La teinte sépare mieux les espèces que le RGB brut
LAB	l_mean, l_std, a_mean, a_std, b_mean, b_std	Espace perceptuellement uniforme
Texture	edge_density, texture_contrast	Texture des ailes (papillons vs abeilles)

Le choix de ces features est motivé par le fait que les méthodes classiques (SVM, RF) ont besoin de descripteurs discriminants bien conçus. Avec seulement 248 échantillons, il est plus efficace d'enrichir les features que d'utiliser des modèles plus complexes.

3. Data Visualization

3.1 Répartition des classes (bug type et species)

Le dataset est fortement déséquilibré. Bee et Bumblebee représentent 87% des échantillons (215/248), tandis que les trois autres classes en totalisent seulement 33. Ce déséquilibre impacte directement les performances des modèles sur les classes minoritaires.




Figure 1 : Distribution des bug types (gauche) et des species (droite)

La colonne « species » révèle 25 espèces distinctes. Les plus représentées sont Bombus hortorum (71) et Apis mellifera (58). Chaque bug type regroupe plusieurs espèces, ce qui explique la variabilité intra-classe. Par exemple, les Bumblebees incluent Bombus hortorum, Bombus pascuorum et Bombus lapidarius qui ont des colorations différentes entre eux.




Figure 2 : Composition en espèces au sein de chaque bug type

3.2 PCA (Analyse en Composantes Principales)

On standardise les features (StandardScaler) puis on applique une PCA pour projeter en 2D. Les deux premières composantes principales expliquent environ 36% et 19% de la variance respectivement, soit 55% au total.




Figure 3 : Projection PCA des features en 2 dimensions

On constate que Bee et Bumblebee occupent des régions largement superposées, ce qui confirme leur proximité dans l'espace des features. Les Butterfly forment un nuage plus dispersé mais avec quelques individus bien séparés. Les Hover fly et Wasp, avec seulement 9 échantillons chacun, sont éparpillés et ne forment pas de cluster distinct.

3.3 Projections non-linéaires

On utilise deux méthodes non-linéaires pour voir si elles révèlent une structure que la PCA ne capte pas.

t-SNE (perplexity=30) : t-SNE optimise la préservation des distances locales. On observe une meilleure séparation visuelle des Butterfly et de certains Wasp par rapport à la PCA. La frontière entre Bee et Bumblebee reste floue, ce qui est cohérent avec les performances de nos modèles.




Figure 4 : Projection t-SNE

Isomap (n_neighbors=10) : Isomap est une méthode basée sur les distances géodésiques sur la variété des données. Le résultat montre une disposition similaire à la PCA mais avec une meilleure séparation des classes minoritaires aux extrémités de la projection.




Figure 5 — Projection Isomap

4. Machine Learning

On évalue plusieurs algorithmes en cross-validation stratifiée à 5 folds. La stratification assure que chaque fold maintient la proportion des classes. La métrique principale est le F1 macro : elle donne un poids égal à chaque classe indépendamment de sa fréquence, ce qui est adapté au déséquilibre du dataset.

4.1 SVM: Support Vector Machine (RBF kernel)

Paramètres : $C=10$, $\gamma=\text{scale}$, $\text{kernel}=\text{RBF}$, $\text{class_weight}=\text{balanced}$. Le $\text{class_weight}=\text{balanced}$ ajuste les poids de chaque classe en fonction inverse de leur fréquence.

Résultats : F1 macro = 0.76, Accuracy = 0.86. C'est le meilleur modèle. Le SVM avec noyau RBF projette les données dans un espace de dimension supérieure où les classes deviennent séparables. Avec des features bien conçues et un petit dataset, le SVM est souvent le meilleur choix car il maximise la marge entre les classes.

Le SVM classe correctement la majorité des Bee et Bumblebee. Les erreurs résiduelles sont principalement des confusions Bee/Bumblebee, ce qui est attendu vu leur proximité morphologique.

4.2 KNN: K-Nearest Neighbors

Paramètres : $k=5$, $\text{weights}=\text{distance}$, $\text{metric}=\text{Manhattan}$.

Résultats : F1 macro = 0.60, Accuracy = 0.78. Le KNN est pénalisé par le déséquilibre : avec 5 voisins, les classes majoritaires dominent. La dimensionnalité élevée (~40 features) rend les distances moins discriminantes.

4.3 Random Forest (méthode d'ensemble)

Paramètres : $n_{\text{estimators}}=300$, $\text{class_weight}=\text{balanced}$.

Résultats : F1 macro = 0.71, Accuracy = 0.82. Deuxième meilleur modèle. La RF gère bien les features hétérogènes sans normalisation. Les feature importances confirment la contribution des descripteurs HSV et des moments de Hu.

4.4 Gradient Boosting

Paramètres : $n_{\text{estimators}}=200$, $\text{max_depth}=5$.

Résultats : F1 macro = 0.52, Accuracy = 0.76. Sous-performe car il n'a pas de mécanisme de class_weight intégré et optimise l'accuracy globale au détriment des classes minoritaires.

4.5 MLP — Multi-Layer Perceptron (Deep Learning, optionnel)

Paramètres : 2 couches cachées (128, 64), ReLU, Adam, $\alpha=0.001$, early stopping, $\text{max_iter}=600$.

Résultats : F1 macro = 0.35, Accuracy = 0.75. Le MLP est le moins performant. Avec 248 échantillons, un réseau de neurones n'a pas assez de données pour généraliser et prédit presque exclusivement les classes majoritaires. Cas classique où le Deep Learning est contre-productif sur un petit dataset.

4.6 Synthèse

Modèle	Type	F1 Macro	Accuracy	Precision	Recall
SVM (RBF)	Supervisé classique	0.76	0.86	0.83	0.71
Random Forest	Ensemble	0.71	0.82	0.78	0.66
KNN	Supervisé classique	0.60	0.78	0.78	0.56
Gradient Boosting	Ensemble	0.52	0.76	0.58	0.49
MLP	Deep Learning	0.35	0.75	0.50	0.36

La matrice de confusion du SVM montre que les erreurs sont concentrées entre Bee et Bumblebee. Les classes minoritaires ont un recall plus faible mais non nul grâce au class_weight balanced.




Figure 6 — Matrice de confusion du SVM (cross-validation)

5. Clustering

On applique deux méthodes de clustering non-supervisé ($k=5$) pour évaluer si la structure naturelle des données reflète les labels.

5.1 K-Means

Paramètres : $k=5$, $n_{\text{init}}=30$. Résultats : Silhouette = 0.12, ARI = 0.14, NMI = 0.21. Le silhouette score faible montre que les clusters ne sont pas bien définis. K-Means tend à découper l'espace en parts égales, ce qui ne correspond pas à la distribution réelle.

5.2 Clustering Agglomératif

Paramètres : $k=5$, linkage=Ward. Résultats : Silhouette = 0.10, ARI = 0.20, NMI = 0.26. Légèrement meilleur en ARI et NMI, la structure hiérarchique capte mieux les sous-groupes. Mais dans l'ensemble, le clustering non-supervisé peine à retrouver les labels.

Méthode	Silhouette	ARI	NMI
K-Means ($k=5$)	0.12	0.14	0.21
Agglomerative (Ward)	0.10	0.20	0.26




Figure 7 — Clusters K-Means sur projection PCA

6. Conclusion

Le modèle retenu pour la soumission est le SVM (RBF) avec $C=10$, $\gamma=\text{scale}$ et $\text{class_weight}=\text{balanced}$. Il obtient le meilleur F1 macro de 0.76 en cross-validation stratifiée.

La pipeline de prédiction : (1) extraction des mêmes features sur les images test, (2) standardisation avec le scaler entraîné sur le train set, (3) prédiction avec le SVM. Le CSV produit contient les colonnes « ID » et « bug type » pour les images 251 à 347.

Ce qu'on retient :

- Le feature engineering est plus déterminant que le choix du modèle sur un petit dataset.
- L'ajout de features HSV, LAB, Hu moments et texture a fait gagner +16 points de F1 macro.
- Le $\text{class_weight}=\text{balanced}$ est indispensable avec des classes déséquilibrées.
- Le Deep Learning n'est pas adapté à 248 échantillons.
- La difficulté principale reste la confusion Bee/Bumblebee, due à leur proximité morphologique réelle.